MUSHROOM CLASSSIFICATION API

DATASET

Dataset reale basato su 23 specie di funghi con lamelle appartenenti alle famiglie Agaricus e Lepiota

Si compone di :

- 8124 campioni
- 22 feature categoriche
- 2 classi target (edible=e, poisonous=p)

ANALISI DEI DATI

L’analisi dei dati ci mostra che il dataset è quasi pulito.

Il risultato di **df.isnull().sum()** produce output che indica la colonna **stalk-root** avente **2480**(circa 30% del dataset) valori **NaN**

L’unica pulizia riguarda la sostituzione di valori **NaN** con “**Unknown**” per evitare errori nei modelli di ML.

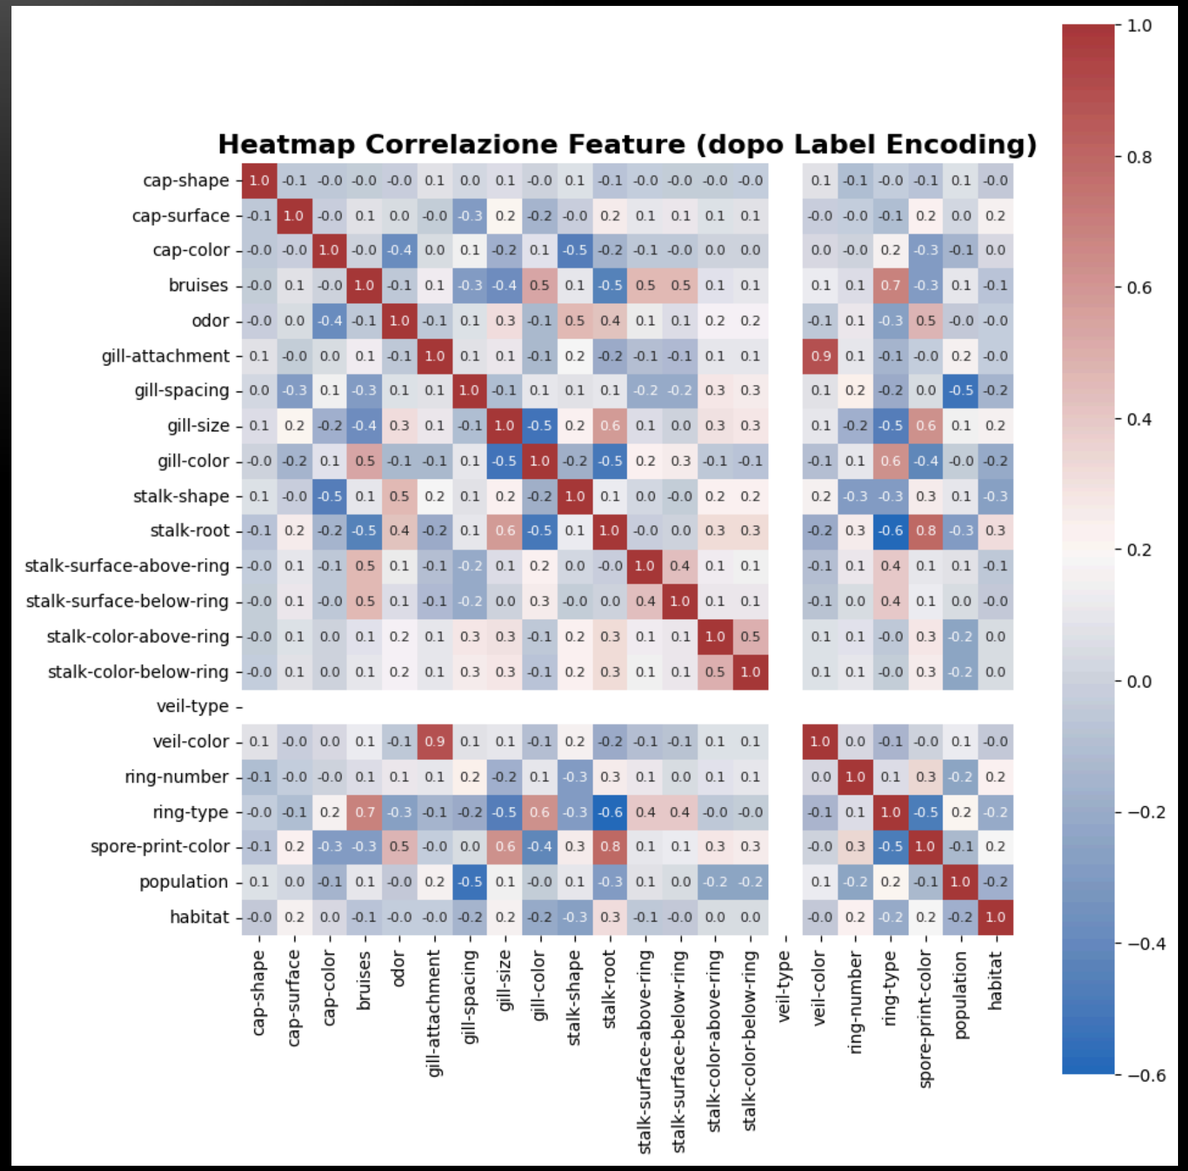

HEATMAP PRE-FEATURE ENGINEERING

Dalla heatmap, possiamo notare la correlazione tra varie caratteristiche.

Ad esempio:

- correlazione positiva tra: gill-attachment e veil-color (0.9), stalk-root e stalk-surface-above-ring (0.8)
- correlazione negativa tra: stalk-root e gill-color(-0.6), gill-spacing e gill-color(-0.5)

Si nota veil-type con correlazione 0 ovvero, valore costante (da rimuovere)

FEATURE ENGINEERING

Profilo	Feature Combinate	Motivazione
profilo_cappello	cap-shape + cap-surface + cap-color	Il cappello è il principale indicatore visivo della specie
profilo_lamelle	gill-attachment + gill-spacing + gill-size + gill-color	Le lamelle sono fortemente correlate alla tossicità
profilo_gambo	stalk-shape + stalk-root + stalk-surface (above/below) + stalk-color (above/below)	Struttura del gambo distintiva per specie
profilo_anello	ring-number + ring-type	Presenza e tipo di anello discriminante
profilo_ambientale	population + habitat	Habitat naturale indicativo della specie
profilo_odore_e_colore_spore	odor + spore-print-color	**Quasi perfetta separazione** tra classi

Per ridurre la dimensionalità e migliorare le prestazioni, le feature originali sono state combinate in 6 profili compositi:

- profilo_cappello
- profilo_lamelle
- profilo_gambo
- profilo_anello
- profilo_ambientale
- profilo_odore_e_colore_spore

Le classi del target sono stati trasformati in:

- 0 = Commestibile (Edible) 🍄
- 1 = Velenoso (Poisonous) ☠️

HEATMAP POST-FEATURE ENGINEERING

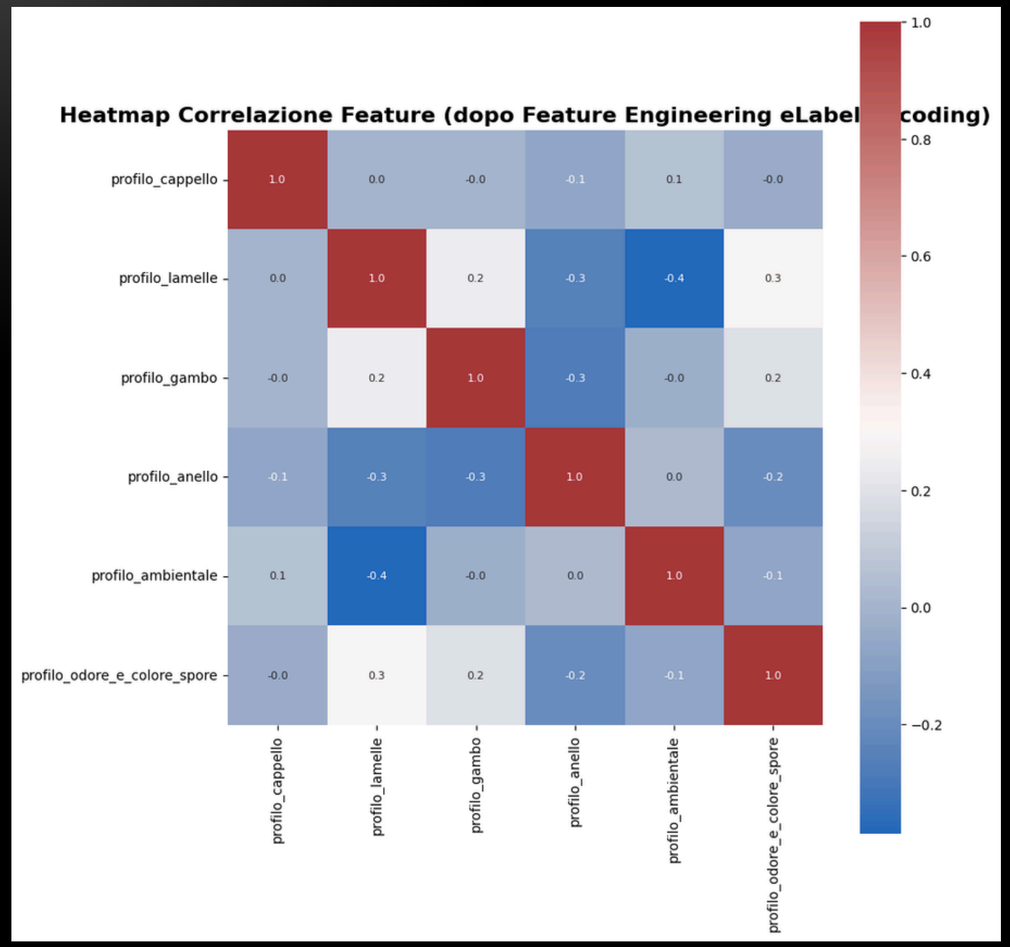

Dopo la Feature Engineering, la heatmap mostra una bassa multicolinearità tra i profili, utile per rendere i modelli stabili e interpretabili

Ad esempio:

- profilo_odore_e_colore_spore mostra correlazione negativa con profilo_lamelle (-0.4)
- profilo_cappello e profilo_lamelle sono relativamente indipendenti (0.0)

LOGISTIC REGRESSION

Logica Matematica :

$$P(y=1|x) = \sigma(w^T x + b) = \frac{1}{1+e^{-(w^T x+b)}}$$

Dove:

- w =vettore dei pesi
- b= bias
- σ = funzione sigmoide

Decision Boundry :

$$\text{Classe} = \begin{cases} 1 \text{ (velenoso)} & \text{se } P(y=1|x) \geq 0.5 \\ 0 \text{ (commestibile)} & \text{se } P(y=1|x) < 0.5 \end{cases}$$

La regressione logistica usa una combinazione lineare delle feature.

Invece di restituire un numero qualsiasi (come nella regressione lineare), restituisce una probabilità tra 0 e 1 grazie alla funzione sigmoide.

Il risultato è la probabilità che l'osservazione appartenga alla classe 1.

Il modello richiede StandardScaler per normalizzare le feature encodate

XGBOOST

Funzione obiettivo :

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

Dove:

- l = loss function(lod loss per classificazione binaria
- Ω(f) = termine di regolarizzazione (penalizza la complessità dell'albero)

XGBoost(Extreme Gradient Boosting) è un algoritmo basato su alberi decisionali e gradient boosting.

Principio:

- Costruisce sequenzialmente alberi decisionali dove ogni nuovo albero corregge gli errori dei precedenti.

Include regolarizzazione per ridurre l'overfitting

DEEP NEURAL NETWORK

Architettura :

```
Input Layer (6 features)
    ↓
Dense(128, ReLU) + BatchNorm + Dropout(0.3)
    ↓
Dense(64, ReLU) + BatchNorm + Dropout(0.2)
    ↓
Dense(32, ReLU) + Dropout(0.1)
    ↓
Output(1, Sigmoid) → Probabilità [0,1]
```

La Rete neurale usata è di tipo feed-forward con architettura a 4 layer

Funzioni di Attivazione:

- ReLU (Hidden Layers): f(x)=max(0,x)
- Sigmoid (Output): σ(x)=1/1+e^-x

Loss Function: Binary Crossentropy

Tecniche di Regolarizzazione:

- Batch Normalization: Normalizza attivazioni tra layer per stabil
- Dropout: Disattiva casualmente neuroni durante training (previene overfitting)
- Early Stopping: Monitora validation loss e ferma il training (patience=15)

VALUTAZIONE MODELLI

```
Accuracy: 1.0
              precision    recall  f1-score   support

           0       1.00      1.00      1.00       842
           1       1.00      1.00      1.00       783

    accuracy                           1.00      1625
   macro avg       1.00      1.00      1.00      1625
weighted avg       1.00      1.00      1.00      1625
```

```
Logistic Regression
Accuracy: 0.8683076923076923
              precision    recall  f1-score   support

           0       0.85      0.91      0.88       842
           1       0.90      0.82      0.86       783

    accuracy                           0.87      1625
   macro avg       0.87      0.87      0.87      1625
weighted avg       0.87      0.87      0.87      1625
```

Valutando i modelli creati, tutti avevano un alto valore per l'accuracy volendo dire che i modelli sono bravi a predire se un fungo è velenoso o meno in maniera precisa

Model	Accuracy	Precision	Recall	F1-score
Neural Network	1.0000	1.0000	1.0000	1.0000